

跨模型不确定性感知的顺式调控元件最小编辑：细胞类型选择性设计

夏昂然

陕西师范大学化学化工学院

陕西省西安市长安区西长安街620号 710119

通信邮箱: haangyeon@snnu.edu.cn

摘要

研究背景与目的： 顺式调控元件（CRE）编码细胞类型选择性的基因表达，但序列-活性模型很少被转化为保留天然调控骨架的紧凑变异体面板。我们开发了SafeEdit-CRE，用于选择既能保持跨模型特异性、又能显著降低预测不确定性的最小编辑方案，产出可审计的CRE变异库，直接适用于报告基因筛选。

研究方法： SafeEdit-CRE将已发表的Malinois细胞类型特异性预测器与架构差异的评审集成模型、验证校准的不确定性、序列域控制以及约束束搜索相结合。在固定编辑预算（1、5、10、20个核苷酸）下编辑天然200-nt CRE，并由完全排除在候选生成之外的独立训练多核集成模型进行评估。

研究结果： 在K562、HepG2和SK-N-SH三种细胞的600个留出CRE亲本上，跨模型特异性裕度增益从贪婪编辑的0.822提升至SafeEdit-CRE的0.877（配对差值0.055；95% CI 0.040–0.071）。与计算量匹配的主模型束搜索相比，SafeEdit-CRE维持了高度吻合的预测特异性（差值–0.004；95% CI –0.011–0.004），而跨模型集成不确定性从0.335降至0.314。在90个非重叠亲本的锁定验证基准中，60.6%的SafeEdit-CRE设计通过了全部九项预设的序列和模型一致性检查，相比之下贪婪编辑为38.8%、随机替换为13.1%（配对差值+21.8个百分点；95% CI 18.3–25.3）。

研究结论： SafeEdit-CRE提供了一种可重复的序列工程策略，用于解析细胞类型特异性调控语法，并产出了包含74个Tier A CRE变异的精选文库，覆盖三种细胞类型和四种编辑预算，优先用于报告基因筛选。通过将搜索与跨模型审计分离，并提供带有序列域防护的明确编辑预算，该框架降低了实验风险，产出了可解释的候选序列，可直接应用于合成调控元件设计、功能性变异优先排序和理性CRE工程化。

关键词： 顺式调控元件；转录调控；功能基因组学；细胞类型特异性；MPRA；调控序列设计；机器学习

1 引言

顺式调控元件（CRE）通过转录因子结合位点及其周围序列上下文，编码基因表达的时空特异性 [1–5]。CRE长度短，便于合成，其活性可直接测量。大规模平行报告基因实验（MPRA）、STARR-seq和饱和突变分析如今能够并行定量数千至数十万条调控序列和变异的效应 [6–11]。这些数据推动了从早期卷积和混合序列模型到长程架构以及合成增强子设计模型的发展 [12–21]。

然而，将这些预测模型转化为实验上可操作的CRE变异面板，仍然是调控基因组学及其下游应用的实际瓶颈。大多数设计策略要么返回无约束的高分序列，要么生成从头增强子，难以将模型的内部逻辑与天然调控元件的模块化语法联系起来——更优先选出那些在后续实验中真正能验证的候选。当研究目标是理解局部序列改变如何改变细胞类型特异性输出，或者为基因治疗、合成生物学、疾病相关非编码变异的功能解析而工程化组织特异性调控元件时，我们真正需要的是锚定在天然CRE骨架上的一组紧凑、可解释的编辑，并内置防护机制来降低实验验证失败的比例。

大多数调控设计研究强调从头生成或直接得分最大化 [21–23]。而当起点是一条天然调控元件、只允许少数替换时，问题就完全不同了。我们将这一设定称为最小编辑：目标是在几乎完整保留亲本CRE的前提下，

提高细胞类型选择性。天然亲本提供序列上下文，编辑预算同时固定设计距离和合成负担。因此，每个候选变异都可以被视为对现有调控骨架的可控扰动。

单一预测器的搜索可能将最高分给那些利用了模型特有行为的序列，即使该预测器在留出天然序列上表现良好 [24–27]。贪婪搜索尤其容易受此影响，因为每一步替换都是依据单一目标的即时收益来保留的。更宽的束采样更多编辑路径，但仍然用同一个模型排序。尚未解决的问题是选择：如何找出一小部分可解释的编辑，其预测效应在不同模型间都能保持。独立训练的评审模型和经过校准的不确定性为做出这种选择提供了直接标准。

我们开发了SafeEdit-CRE来解决这个问题（图 1）。已发表的Malinois预测器 [21]提供主要的细胞类型特异性目标。一个架构差异的残基-扩张CNN集成在约束束搜索过程中担任评审，同时经过验证校准的不确定性和序列域控制（链一致性、GC偏移、同源多聚体、6聚体天然性）防范分布外编辑。选定序列随后由第二个独立训练的多核集成评估，该集成完全排除在搜索过程之外，提供另一层跨模型评估。固定编辑预算（1、5、10、20个核苷酸）使得可以量化设计自由度的影响，而不会将最小编辑与无约束序列生成混为一谈。

我们用三个对照来基准化SafeEdit-CRE：随机替换作为零基准，迭代贪婪优化以检验局部得分最大化是否足够，以及一个计算量匹配的主模型束搜索——使用与SafeEdit相同束宽和扩展计划，但只依赖主预测器得分。计算量匹配的束搜索至关重要，因为它将跨模型选择的收益与更大候选池的收益分离开来。我们评估四个互补终点：在K562、HepG2和SK-N-SH三种细胞的600个留出天然CRE亲本上的跨模型泛化；在90个非重叠验证亲本上的九准则设计质量基准；按细胞类型和编辑预算的分层分析；以及完整重搜索消融，用以识别哪些组件调控着预测选择性与不确定性之间的权衡。

SafeEdit-CRE在跨模型特异性裕度上超越了贪婪编辑，并在预测特异性上与计算量匹配的束搜索相当，同时选出了不确定性更低的变异。在锁定的设计质量基准中，通过率从38.8%提升至60.6%。最终的Tier A面板包含74条序列，分布于三种细胞类型和全部四种编辑预算，为报告基因筛选和后续细胞类型特异性调控语法分析提供了聚焦的文库。

2 材料与方法

2.1 MPRA数据与固定染色体划分

我们使用了Gosai等人 [21]公开的MPRA序列性能表，包含K562、HepG2和SK-N-SH的活性估计值和标准误差。上游染色体划分保持不变：19、21和X号染色体为验证集；7号和13号染色体为测试集；其余符合条件的染色体为训练集。记录要求仅包含A/C/G/T、长度不超过200 nt、含有有限的活性和标准误差、且最大报告log倍变化标准误差低于1.0。全数据模型训练前移除精确序列重复。短于200 nt的序列在200位置张量中居中，第五个输入通道标记有效位置。

2.2 泄漏与亲本重叠审计

我们检查了200 nt构建体之间的精确同一性、反向互补同一性、主变异组成员关系，以及跨拆分的汉明距离（最多3个）。近重复审计识别出27对跨拆分组对，涉及8个训练侧变异组。亲本拒绝列表包括早期开发和验证亲本，匹配标识符、序列哈希和审计标记的冲突。600亲本主要评估表在不使用活性标签的情况下创建：按ID + tab + sequence的SHA-256对符合条件的200 nt测试序列排序，在拒绝列表移除后选取前600个。消融研究使用固定的180亲本子集，九准则基准使用固定的90亲本验证子集——在发现6个名义亲本与早期探索性基准重叠后，按标识符排除，未参考结果。各阶段的亲本重叠通过标识符和序列哈希检查。

全数据加载器执行了精确去重。独立的汉明距离清单应用于亲本资格审查，确保任何被标记的近重复都不被纳入编辑基准。




图 1: SafeEdit-CRE研究设计。 天然CRE亲本在固定替换预算下进行编辑。Malinois提供主要特异性目标，残基-扩张CNN集成在约束束搜索期间提供评审。经过验证校准的不确定性和序列域行为控制防范不可信编辑。选定序列随后由第二个独立训练的多核集成评估，用于跨模型泛化评估。

2.3 主预测器

Gosai等人[21]发布的Malinois BassetBranched作为主预测器。检查点以仅权重模式加载。每条序列在正向和反向互补方向各评估一次，活性预测取平均。对于靶细胞 t ，特异性裕度定义为

$$M_t(x) = f_t(x) - \max_{j \neq t} f_j(x), \quad (1)$$

其中 $f_j(x)$ 是细胞类型 j 的预测活性。候选裕度增益为 $\Delta M_t = M_t(x_{\text{edit}}) - M_t(x_{\text{parent}})$ 。

2.4 评审器与跨模型评估集成

我们训练了两个架构差异化的异方差CNN，在全部质量过滤的训练记录上进行训练，以在不同阶段提供留出评估。评审集成是一个残基-扩张一维CNN，具有11 nt的主干、扩张率1、2、4、8的残基块，以及共享的均值和对数方差头；它在候选搜索期间可用于跨模型重排序。跨模型评估集成（在程序性协议中称为冻结后评估器）是一个多核CNN，具有并行的3、7、15和21 nt分支、逐点融合、深度卷积以及独立的均值和方差头[28, 29]。使用种子集成和预测方差遵循已建立的神经网络不确定性策略[29–31]。每种架构使用三个固定种子：评审器为20260721–20260723，跨模型评估集成为20260731–20260733。

模型使用AdamW[32]训练最多20个epoch，采用余弦学习率衰减、批次大小256、学习率 10^{-3} 、权重衰减 10^{-4} 、dropout 0.25[33]以及梯度裁剪5.0。损失结合了异方差高斯负对数似然、报告的测量标准误以及权重为0.1的反向互补一致性惩罚。早停使用验证集平均Pearson相关系数，耐心为6。测试记录未用于选择检查

点、架构、超参数或方差尺度。

对于每个集成，预测是三个种子特定均值的平均，遵循自助聚合集成预测的精神 [34]。预测方差结合了平均学习到的模型内方差和种子间方差。每种细胞类型的一个乘法方差尺度仅从验证集的平方误差估计，然后冻结 [26]。跨模型评估集成从未被搜索代码导入；它仅在候选文件及其SHA-256哈希写入后（程序性冻结）应用，确保生成与评估完全分离。

2.5 编辑方法

所有方法均针对靶细胞K562、HepG2和SK-N-SH，在精确替换预算1、5、10和20下进行评估。沿搜索路径每个位置最多编辑一次。

随机匹配编辑。 位置和非参考等位基因均匀无放回抽样。600亲本评估使用三次独立固定种子（20260801–20260803）。方法级比较时，数值终点在重复间取平均；从不选择最优随机重复。

贪婪Malinois。 每一步，每个可用的单核苷酸替换都由主特异性裕度打分，保留得分最高的替换。搜索期间不执行评审、不确定性或序列域约束。

主束（计算量匹配对照）。 一束24个部分编辑集每次扩展一个替换。每步最多保留96个候选，按主得分排序——主得分为主裕度减去0.05倍正向/反向链不一致性。束宽、最大扩展深度和预筛选大小与SafeEdit-CRE完全匹配。不使用评审得分、不确定性惩罚或序列域重排序。

SafeEdit-CRE。 SafeEdit-CRE使用与主束相同的主扩展和计算预算。主候选的佼佼者由评审集成根据下式重新打分

$$S(x) = M_t^{\text{primary}}(x) + 0.3M_t^{\text{reviewer}}(x) - 0.1D_{\text{strand}}(x) - 0.05U_{\text{reviewer}}(x). \quad (2)$$

候选经过预过滤，检查同源多聚体长度是否超过8、以及相对于亲本的绝对GC变化是否超过0.12。重排序使用验证导出的、预算特定的链不一致性、评审不确定性、6聚体天然性变化、GC变化和同源多聚体长度限值。优先选择正的主裕度和评审裕度；当没有候选通过每个首选条件时，回退得分保留一条路径。在每个请求的预算处独立取快照。

序列天然性是重叠6聚体在天然训练序列频率下的位置无关平均对数似然。它在重排序期间用作计算序列域诊断。

2.6 九准则设计基准

九准则基准（G4）使用90条测试集CRE亲本，与开发或主要评估亲本无重叠（96个名义亲本中有6个在发现与探索性基准的标识符级重叠后被排除，未参考结果）。对于每个方法–亲本–靶标–预算组合，记录九项布尔检查：非负主靶标增益、正主裕度增益、正评审裕度传递、链不一致性在域内、评审不确定性在域内、天然性在域内、GC变化在域内、同源多聚体安全性、精确编辑预算。阈值从验证集随机编辑校准，并在评估前锁定。不可行组合必须保留在结果表中并标记为失败。

主要对比是SafeEdit-CRE与贪婪之间的配对九准则通过率差值。我们使用100,000次重复的亲本簇自助法计算95%置信区间，保留每个亲本贡献的12个靶标–预算条件之间的依赖关系。保留汇总二元结果上的精确双侧McNemar检验作为描述性敏感性分析。使用分层的靶标–预算汇总来检验异质性。

2.7 主要跨模型评估（600亲本）

主要评估（G8）评估了600个标签盲、先前未使用的亲本，方法包括随机匹配、贪婪、主束和SafeEdit-CRE。搜索产生了43,200条序列行，因为随机编辑有三次重复。方法级统计时，三次随机重复平均为每个亲本–靶标–预算组合一个数值记录，共28,800行。此折叠表仅用于数值比较，从不用于选择DNA序列。候选文件在跨模型集成推理前冻结（写入SHA-256哈希）。

主要终点是跨模型特异性裕度增益。次要终点是跨模型靶标增益、正裕度比例和跨模型集成不确定性。对于每个对比，指标首先在一个亲本内的12个靶标-预算条件上平均；然后100,000次自助采样对600个亲本有放回重采样。不可行的束搜索结果作为零编辑、零增益的亲本序列保留。

2.8 完整重搜索消融

在180个亲本上独立重运行七次搜索：主束、完整SafeEdit-CRE、无评审得分的SafeEdit-CRE、无不确定性惩罚、无链惩罚、无天然性重排序、以及无序列预过滤器。与事后删除过滤器不同，每个消融都可能生成不同的序列。然后跨模型评估集成在全部15,120条候选行上重新运行。我们验证了候选键、精确编辑预算、有限数值、以及跨模型靶标和裕度增益的独立计算。配对亲本簇自助区间使用与主要评估相同的程序。

2.9 候选分层

3,240条九准则基准候选被组织为三个计算优先级层级。Tier A要求：SafeEdit-CRE生成、通过全部九项准则、非负靶标增益、正主裕度和评审裕度增益、精确编辑预算、无合成风险标记、且位于或接近双目标主-评审帕累托前沿。近帕累托候选指在前沿的5%相对或0.1绝对范围内。Tier B通过核心活性和跨模型检查，但允许帕累托次优或轻度天然性偏差。Tier C未通过一项或多项硬性检查，仅保留用于诊断分析。补充表 S10提供了跨越K562、HepG2和SK-N-SH的三个代表性Tier A示例。

2.10 软件、可重复性与报告

初步开发阶段在NVIDIA RTX 3060笔记本GPU上运行。最终基准在Slurm管理的RTX 3080 Ti计算节点上运行。固定种子、环境记录、代码哈希、候选哈希、检查点哈希和运行日志均提供在Zenodo永久归档(v1.0.0)中。统计值和图件由独立分析脚本直接从候选级表格重新生成，使用PyTorch、NumPy、pandas和Matplotlib实现[35–38]。全部代码、环境文件、最小复现脚本、核心统计输入、候选序列和预训练模型检查点均包含在公开发布中。

3 结果

3.1 细胞类型选择性CRE设计的活性图景建模

公开的MPRA序列性能表包含798,064条序列记录。经过固定质量过滤、序列验证、长度过滤和精确序列去重后，全数据加载器保留了749,054条记录：627,661条训练、58,811条验证和62,582条测试。19、21和X号染色体组成验证集；7号和13号染色体组成测试集；其余符合条件的染色体组成训练集。亲本选择使用标识符和序列哈希，从不使用活性标签。

正向/反向互补平均后的Malinois预测重现了已发表的测试性能（三种细胞的平均Pearson $r = 0.884$ 、平均Spearman $\rho = 0.825$ ）。在相同的62,582条测试记录上，三成员残基-扩张评审集成达到平均Pearson $r = 0.849$ ，而三成员多核评估器达到 $r = 0.793$ （图 2A）。它们不同的卷积结构使得一个集成可以在搜索期间评审候选，另一个则用于评估冻结的候选集。

预测不确定性由学习到的异方差方差和种子间变异共同构成，乘法缩放仅在验证数据上估计。跨细胞类型，评审模型的95%测试区间覆盖率为0.930–0.940，跨模型评估器为0.923–0.935（图 2B）。评审不确定性与绝对误差的Spearman相关性为 $\rho = 0.399$ –0.448；跨模型评估器不确定性给出 $\rho = 0.400$ –0.467（图 2C）。拒绝曲线显示，随着高不确定性记录被逐步移除，平均绝对误差下降（图 2D），支持不确定性引导的候选分类。

3.2 SafeEdit-CRE在600个留出亲本上提升跨模型细胞类型选择性

我们在600个留出的200-nt天然CRE亲本上评估了四种编辑方法，这些亲本是在去除所有历史亲本标识符和序列哈希后按SHA-256排序选出的。每种方法针对三个靶细胞（K562、HepG2、SK-N-SH）和四个替换预




图 2: 预测性能和不确定性诊断。 **A**, 主模型、评审模型和跨模型评估器按细胞类型划分的测试集Pearson相关系数。**B**, 仅验证集方差缩放后, 80%、90%和95%名义水平下的观测测试覆盖率; 虚线标记理想校准。**C**, 预测不确定性 with 绝对误差之间的Spearman关联。**D**, 逐步拒绝最不确定记录后的平均测试误差。所有神经集成都包含三个独立种子的成员。

算 (1、5、10、20 nt) 各运行一次, 产生28,800个方法级比较。随机编辑使用三次独立重复, 其指标取平均, 不做最优选择。候选生成后, 序列被传递给未参与搜索的留出跨模型评估器。

在全部7,200个亲本-靶标-预算条件下, SafeEdit-CRE的平均跨模型特异性裕度增益为0.877, 而迭代贪婪优化为0.822 (配对差值0.055; 亲本簇自助法95% CI, 0.040–0.071), 随机匹配编辑为0.001 (差值0.876; 95% CI, 0.856–0.896) (表 1; 图 3A)。跨模型裕度增益为正的条件的比例, SafeEdit-CRE为95.4%、贪婪为97.1%, 表明对贪婪的优势来自增益的幅度和分布, 而非更多的正例。因此, SafeEdit-CRE的优势体现在整个条件集上更大的增益, 而不是正例比例的增加。

计算量匹配的主束搜索——使用与SafeEdit-CRE相同的束宽、扩展计划和搜索预算, 但仅依赖主Malinois预测器进行候选排序——的平均跨模型裕度增益为0.881。SafeEdit-CRE与这一性能高度吻合 (配对差值–0.0036; 95% CI, –0.0114–0.0043; 图 3B), 同时绝对靶标增益降低了0.205 (95% CI, –0.229–0.181), 跨模型集成不确定性降低了0.0209 (95% CI, –0.0251–0.0166) (图 3C–D)。相对于贪婪优化, SafeEdit-CRE将特异性裕度提升了0.055 (95% CI, 0.040–0.071), 靶标增益降低了0.141 (95% CI, –0.177–0.106), 不确定性降低了0.0153 (95% CI, –0.0214–0.0091)。

计算量匹配的束搜索表明, 仅靠搜索广度就可以恢复同等水平的预测特异性。SafeEdit-CRE改变的是从这个庞大候选池中选择哪一个: 它选出的变异具有更低的集成不确定性和更小的靶标得分偏移, 同时保留了特异性裕度。

表 1: 600个留出亲本上的跨模型评估结果。

方法	平均裕度增益	平均靶标增益	正裕度比例(%)	平均不确定性
随机匹配	0.001	0.012	48.6	0.185
贪婪Malinois	0.822	1.803	97.1	0.329
主束(计算量匹配)	0.881	1.866	94.8	0.335
SafeEdit-CRE	0.877	1.661	95.4	0.314

表 2: 90个非重叠验证亲本上的九准则设计基准。

方法	设计数	通过数	通过率(%)	亲本自助法95% CI(%)
随机匹配	1,080	142	13.1	10.6–15.8
贪婪Malinois	1,080	419	38.8	34.6–42.9
SafeEdit-CRE	1,080	654	60.6	55.6–65.3

序列域预过滤器在600个亲本中有12个（2.0%）在至少一个条件下返回了零编辑结果。在所有汇总中保留这些结果，既保持了预设的分母，也量化了序列安全措施的实际代价。

3.3 90个非重叠验证亲本上的设计准则基准

为了评估SafeEdit-CRE设计不仅在跨模型评估下得分高，而且满足广泛的序列质量和模型一致性标准，我们对90条亲本序列应用了预设的九准则设计基准，这些亲本与任何开发或主要评估亲本都没有重叠（在发现6个名义亲本与早期探索性基准存在标识符级重叠后，将其排除）。对于每个方法–亲本–靶标–预算组合，我们记录：非负主靶标增益、正主裕度增益、正评审裕度传递、链差异在域内、评审不确定性在域内、天然性在域内、GC变化在域内、同源多聚体安全性、精确编辑预算。阈值来源于验证集随机编辑，并在评估前锁定。

SafeEdit-CRE在1,080个设计中有654个（60.6%）通过了全部九项准则，相比之下贪婪设计为419/1,080（38.8%）、随机设计为142/1,080（13.1%）（表 2；图 4A）。SafeEdit–贪婪的配对差值为21.8个百分点（亲本簇自助法95% CI，18.3–25.3个百分点）。SafeEdit–随机差值为47.4个百分点（95% CI，43.0–51.8个百分点）。相对于贪婪的优势在一碱基预算时较小，在5–20预算时增大（图 4B–D）。

21.8个百分点的差值衡量了在候选生成期间强制执行评审、不确定性和序列域准则的收益。对贪婪设计进行事后筛选，能够通过相同预设准则的变异体明显更少。

3.4 细胞类型和编辑预算效应

跨模型选择的收益因靶细胞类型和编辑预算而异（图 5）。对于K562，SafeEdit–贪婪的跨模型裕度差值从1个编辑的–0.016进展到20个编辑的0.242；对于HepG2，从–0.004进展到0.294。在SK-N-SH中，各预算下的差值范围为–0.078到–0.033，表明活性图景中存在细胞类型特异性的异质性。

与计算量匹配的主束相比，SafeEdit-CRE的差值在所有分层中都保持在紧密的等效范围内：K562为0.004–0.031；HepG2为–0.030–0.004；SK-N-SH为–0.033–0.010，证实了汇总的裕度等效性在靶细胞和编辑预算间均成立。

这一模式与一致性重排序随着合理编辑路径数增长而变得越来越有价值是一致的。在一个替换时，三种定向策略常常都被约束在亲本序列周围的同一小邻域内；在5–20个替换时，跨模型评审过滤掉了那些在主预测器下看起来有利、但在留出集成中传递较差的编辑。SK-N-SH的结果提示，设计阈值应按细胞类型校准，而不是在细胞模型间不加改变地转移。




图 3: 600个留出天然CRE亲本上的跨模型评估。 **A**, 按编辑方法划分的平均留出跨模型特异性裕度增益。**B**, SafeEdit-CRE相对于贪婪和计算量匹配主束的裕度增益配对差值。**C**, 对应的绝对靶标增益配对差值。**D**, 对应的跨模型集成不确定性配对差值。点表示均值; 区间为100,000次重复的亲本簇自助法95%置信区间。随机重复取平均值, 从未按最优结果选择。

3.5 完整重搜索消融识别关键组件

为了确定哪些SafeEdit-CRE组件驱动了观察到的行为, 我们在180个亲本上以七种配置重新运行了完整搜索 (15,120行)。每种配置生成自己的候选序列; 过滤器不是从共享候选表中追溯移除的。跨模型推理在每次搜索后都为每个候选重新计算。

完整SafeEdit-CRE的平均跨模型裕度增益为0.890, 靶标增益为1.705, 不确定性为0.312 (图 6)。匹配的主束的裕度增益为0.890 (配对完整-主束差值0.0002; 95% CI, -0.0145-0.0151), 靶标增益为1.897 (差值-0.192; 95% CI, -0.244-0.143), 不确定性为0.334 (差值-0.0212; 95% CI, -0.0283-0.0140)。

移除天然性重排序后, 跨模型裕度增益升至0.979、靶标增益升至2.017, 不确定性升至0.343。相对于此配置, 完整SafeEdit-CRE将不确定性降低了0.0305 (95% CI, 0.0218-0.0394), 同时裕度调整了0.089 (95% CI, 0.075-0.102)、靶标增益调整了0.312 (95% CI, 0.266-0.360)。移除序列域预过滤器消除了全部48个不可行行, 并通过放宽GC和同源多聚体限制将裕度增益提升至0.910。链和不确定性惩罚的汇总效应较小, 而无评审配置则精确重现了主束结果。

天然性感知重排序对不确定性降低的贡献最大, 而序列域预过滤器决定了合成可行性。移除评审器精确重现了主束结果, 表明评审模型改变了返回的序列, 而不仅仅是在选择后对其做注释。




图 4: 九准则设计基准。 A, 锁定的非重叠90亲本验证基准中的汇总九准则通过率。误差棒为亲本簇自助法95%置信区间。B–D, 分别为K562、HepG2和SK-N-SH按编辑预算分层的通过率。

3.6 Tier A候选文库及代表性示例

从90亲本验证基准的3,240个设计中, 我们导出了一个分层候选文库用于实验筛选。74条Tier A序列由SafeEdit-CRE生成, 通过了全部九项准则, 满足靶标和裕度要求, 无合成风险标记, 且位于或接近主-评审帕累托前沿 (补充表 S9; 补充图 S3)。Tier B包含1,141条备选序列, 它们通过了核心活性和跨模型检查, 但被帕累托支配或轻度偏离某条序列质量准则; 其余2,025条Tier C序列保留用于失效模式分析。得到的74序列Tier A面板覆盖全部三种靶细胞类型和四种编辑预算, 提供了一个紧凑的首轮报告基因筛选集, 而Tier B保留了足够广度用于更大规模的后续MPRA文库。

为说明SafeEdit-CRE设计的性质, 补充表 S10展示了三个代表性Tier A候选——K562、HepG2和SK-N-SH各一个——均在5编辑预算下生成并达到帕累托前沿状态且无合成风险标记。每个示例报告了亲本和编辑后的200-nt序列、编辑位置、主模型和评审特异性裕度增益、主靶细胞活性增益、跨模型预测不确定性的降低、GC含量、天然性以及同源多聚体状态。三者均显示正的主靶标增益和正的评审裕度传递, 同时跨模型不确定性降低。编辑位置附近的局部序列变化被记录为可检验的序列语法假说, 供实验随访。




图 5: 细胞类型和编辑预算效应。 **A–B**, 贪婪、主束和SafeEdit-CRE搜索在三个靶细胞上汇总的跨模型特异性裕度增益和不确定性随编辑预算的变化。**C–D**, SafeEdit-CRE相对于贪婪或计算量匹配主束的按靶标-预算的平均特异性裕度增益差值。**A–B**面板省略了随机编辑, 因其汇总裕度增益接近零。线条和热图单元格为亲本上的描述性均值。编辑预算以nt (核苷酸替换) 为单位。

4 讨论

SafeEdit-CRE围绕一个实际的调控基因组学问题而设计: 当所选序列被第二个模型检验时, 如何用少量替换改变一条天然顺式调控元件, 同时保留细胞类型选择性信号? 现有的序列-活性工作流提供了强大的预测器和日益成熟的设计工具, 但候选排序往往与用作优化目标的同一个预测器绑定 [24, 25, 27]。SafeEdit-CRE将这些角色分开, 并使用跨模型选择来决定哪些最小编辑值得推进。

与迭代贪婪优化最清晰的分野出现在600亲本评估中。SafeEdit-CRE将跨模型特异性裕度增益提高了0.055个标准化单位 (95% CI 0.040–0.071), 尽管贪婪编辑已经在97.1%的条件下产生了正裕度增益。因此, 这种差异是在大多合理编辑中的排序效应: 评审和不确定性标准偏向那些增益更大、且在不同模型间保持一致的变体。这一效应在K562和HepG2的5–20核苷酸预算下最为显著, 因为此时有更多编辑路径可用, 且主模型偏好可能出现分化。

仅靠搜索广度并不能解释这一现象。计算量匹配的主束搜索的裕度增益为0.881, 与SafeEdit-CRE的0.877高度吻合 (差值–0.004; 95% CI –0.011–0.004)。然而SafeEdit-CRE返回的变异具有更低的跨模型不确定性 (0.314对比0.335) 和更小的靶标得分偏移。换言之, 该框架保留了预测的细胞类型特异性目标, 同时选择了候选图景中更不分散的部分。当合成和报告基因能力有限、实验预算更适合花在紧凑、可审计的面板上时, 这种权衡尤其有价值。




图 6: 180个亲本上的完整重搜索消融。 **A**, 相对于完整SafeEdit-CRE的跨模型特异性裕度增益变化。**B**, 对应的绝对靶标增益变化。**C**, 选定候选的平均跨模型集成不确定性。**D**, 不可行搜索行数。每种配置均独立重运行。天然性感知重排序是不确定性降低的主要驱动因素, 而预过滤器的执行则以裕度换取合成可行性。

九准则基准在更苛刻的设计设定下给出了同样的结论。SafeEdit-CRE的设计通过率为60.6%, 而贪婪优化为38.8%, 相差21.8个百分点 (95% CI 18.3–25.3)。完整重搜索消融揭示了原因: 天然性感知重排序对不确定性降低的贡献最大, 而序列域预过滤器在生成过程中强制执行GC和同源多聚体可行性。移除评审器精确重现了主束结果, 表明跨模型评审是改变返回序列的组件, 而不仅仅是在选择后对其做注释。

因此, 输出是一个候选文库, 而不是单一模型最优解。74条Tier A序列通过了全部九项准则, 满足靶标和裕度要求, 不带合成风险标记, 且位于或接近主-评审帕累托前沿。它们覆盖三种靶细胞类型和四种编辑预算, 提供了一个紧凑、表征充分的首轮面板, 用于报告基因筛选和下游调控语法解析; 1,141条Tier B序列则保留了广度, 可用于更大规模的后续MPRA。候选记录保留了亲本序列、编辑后序列、编辑位置、模型特异性增益、不确定性、链一致性、天然性、碱基组成、同源多聚体状态和编辑计数。补充表 S10中的三个代表性示例凸显了具体的序列语法假说: 局部替换在保留更广泛CRE骨架的同时改变细胞类型选择性, 可通过报告基因实验直接检验。

若干设计选择使得比较具有可解释性。亲本选择是标签盲的, 开发和评估亲本通过标识符和序列哈希分开, 随机重复取平均而非按结果选择, 置信区间对整个亲本进行重采样。冻结后评估器排除在候选生成之外, 而计算量匹配的束搜索保持了搜索宽度和扩展成本不变。完整重搜索消融进一步确保了组件效应反映的是不

同的返回序列，而非对一个候选表的追溯过滤。

最直接的生物学产出是一套紧凑、可审计的CRE变异，用于报告基因筛选。本研究的结果确立了计算排序及其跨模型行为；报告基因实验现在可以检验预测的裕度和不确定性排序是否与实测活性一致。由于候选保留了天然CRE骨架和明确的编辑预算，该面板也适用于将局部序列变化映射到细胞类型选择性调控输出的后续实验。除了报告基因筛选之外，最小编辑框架还具有直接的实际意义：Tier A面板可以指导合成基因电路中细胞类型特异性调控元件的设计，帮助优先选择疾病队列中功能性非编码变异进行实验验证，并为利用碱基编辑或先导编辑理性改造内源性CRE提供模板。每个候选都带有记录在案的编辑预算、链一致性检查和天然性评分，降低了选择那些合成失败或产生无法解释结果的序列的实验风险。

SafeEdit-CRE从而提供了一条从序列-活性预测到实验可检验的最小编辑的可重复路径。跨模型选择保留了主要的细胞类型特异性目标，相对于计算量匹配的单模型搜索降低了预测离散度，并产出了一个实用的Tier A面板，而非一长串不透明的无约束高分序列。同样的选择原则可以推广到其他调控预测模型和细胞情境——在这些地方，候选可靠性与名义最优值同样重要。

5 结论

SafeEdit-CRE建立了跨模型不确定性感知的最小编辑范式，为将序列-活性模型转化为紧凑、具有细胞类型选择性的CRE变异库提供了一条实用路径。通过保留天然序列骨架并明确控制编辑距离、模型一致性和预测不确定性，该框架为调控序列语法的功能基因组学研究提供了聚焦的起点。

基金

本研究未接受外部资助。

伦理审查声明

不适用。本研究使用公开的序列和MPRA汇总数据，未涉及人类参与者、可识别的个人数据或动物实验。

知情同意声明

不适用。

数据可用性声明

用于训练Malinois的处理后MPRA测量数据见Gosai等人 [21] 的补充表2。相关的原始数据、处理notebook、模型权重和免疫荧光图像归档于Zenodo记录10698014 (DOI: 10.5281/zenodo.10698014)。所有SafeEdit-CRE代码、环境文件、冻结配置清单、亲本标识符、候选级结果表、统计汇总、分析脚本、固定模型种子以及74个Tier A候选序列均存档于Zenodo永久仓库 (DOI: <https://doi.org/10.5281/zenodo.21458489>; 版本v1.0.0)。该仓库还包含一个最小端到端复现脚本，可从已发布的汇总输入重新生成主要图和统计表。源代码的公共镜像托管于<https://github.com/Haangyeon/SafeEdit-CRE> (版本标签v1.0.0)，用于问题追踪和发布后更新。预训练模型检查点包含在Zenodo归档中。

作者贡献

夏昂然构思了本研究，完成了计算分析，制备了图件和手稿，并批准了提交版本。

利益冲突

作者声明无利益冲突。

致谢

作者感谢ENCODE联合体和Gosai等人的研究团队公开了MPRA测量数据。

生成式AI使用声明

生成式AI工具仅用于语言编辑、文档组织和手稿格式辅助。未使用任何生成式AI系统生成实验或计算数据、执行统计分析或替代作者的科学判断。

参考文献

- [1] Wyeth W. Wasserman and Ann Sandelin. Applied bioinformatics for the identification of regulatory elements. *Nature Reviews Genetics*, 5(4):276–287, 2004. doi: 10.1038/nrg1315.
- [2] ENCODE Project Consortium. An integrated encyclopedia of DNA elements in the human genome. *Nature*, 489(7414):57–74, 2012. doi: 10.1038/nature11247.
- [3] Robert E. Thurman, Eric Rynes, Richard Humbert, et al. The accessible chromatin landscape of the human genome. *Nature*, 489(7414):75–82, 2012. doi: 10.1038/nature11232.
- [4] Roadmap Epigenomics Consortium, Anshul Kundaje, Wouter Meuleman, et al. Integrative analysis of 111 reference human epigenomes. *Nature*, 518(7539):317–330, 2015. doi: 10.1038/nature14248.
- [5] Biswajyoti Sahu et al. Sequence determinants of human gene regulatory elements. *Nature Genetics*, 54:283–294, 2022. doi: 10.1038/s41588-021-01009-4.
- [6] Alexandre Melnikov, Anand Murugan, Xiaolan Zhang, et al. Systematic dissection and optimization of inducible enhancers in human cells using a massively parallel reporter assay. *Nature Biotechnology*, 30(3):271–277, 2012. doi: 10.1038/nbt.2137.
- [7] Cosmas D. Arnold, Daniel Gerlach, Christoph Stelzer, Lukasz M. Boryn, Martina Rath, and Alexander Stark. Genome-wide quantitative enhancer activity maps identified by STARR-seq. *Science*, 339(6123):1074–1077, 2013. doi: 10.1126/science.1232542.
- [8] Ryan Tewhey, Dylan Kotliar, D. S. Park, et al. Direct identification of hundreds of expression-modulating variants using a multiplexed reporter assay. *Cell*, 165(6):1519–1529, 2016. doi: 10.1016/j.cell.2016.04.027.
- [9] Fumitaka Inoue, Martin Kircher, Beth Martin, et al. A systematic comparison reveals substantial differences in chromosomal versus episomal encoding of enhancer activity. *Genome Research*, 27(1):38–52, 2017. doi: 10.1101/gr.212092.116.
- [10] Matthew G. Gordon, Fumitaka Inoue, Beth Martin, et al. lentiMPRA and MPRAflow for high-throughput functional characterization of gene regulatory elements. *Nature Protocols*, 15:2387–2412, 2020. doi: 10.1038/s41596-020-0333-5.
- [11] Martin Kircher, Chenling Xiong, Beth Martin, et al. Saturation mutagenesis of twenty disease-associated regulatory elements at single base-pair resolution. *Nature Communications*, 10:3583, 2019. doi: 10.1038/s41467-019-11526-w.
- [12] Babak Alipanahi, Marco Delvecchio, Patrick C. Gray, et al. Predicting the sequence specificities of DNA- and RNA-binding proteins by deep learning. *Nature Biotechnology*, 33(8):831–838, 2015. doi: 10.1038/nbt.3300.

- [13] Jian Zhou and Olga G. Troyanskaya. Predicting effects of noncoding variants with deep learning-based sequence model. *Nature Methods*, 12(10):931–934, 2015. doi: 10.1038/nmeth.3547.
- [14] Daniel Quang and Xiaohui Xie. DanQ: a hybrid convolutional and recurrent deep neural network for quantifying the function of DNA sequences. *Nucleic Acids Research*, 44(11):e107, 2016. doi: 10.1093/nar/gkw226.
- [15] David R. Kelley, Jasper Snoek, and John L. Rinn. Basset: learning the regulatory code of the accessible genome with deep convolutional neural networks. *Genome Research*, 26(7):990–999, 2016. doi: 10.1101/gr.200535.115.
- [16] David R. Kelley, Yakir A. Reshef, Maxwell Bileschi, et al. Sequential regulatory activity prediction across chromosomes with convolutional neural networks. *Genome Research*, 28(5):739–750, 2018. doi: 10.1101/gr.227819.117.
- [17] Gökçen Eraslan, Žiga Avsec, Julien Gagneur, and Fabian J. Theis. Deep learning: new computational modelling techniques for genomics. *Nature Reviews Genetics*, 20(6):389–403, 2019. doi: 10.1038/s41576-019-0122-6.
- [18] Ziga Avsec, Vikram Agarwal, Daniel Visentin, et al. Effective gene expression prediction from sequence by integrating long-range interactions. *Nature Methods*, 18:1196–1203, 2021. doi: 10.1038/s41592-021-01252-x.
- [19] Bernardo P. de Almeida, Franziska Reiter, Michaela Pagani, and Alexander Stark. DeepSTARR predicts enhancer activity from DNA sequence and enables the de novo design of synthetic enhancers. *Nature Genetics*, 54:613–624, 2022. doi: 10.1038/s41588-022-01048-5.
- [20] Ibrahim I. Taskiran, Katina I. Spanier, Hannah Dickmanken, et al. Cell-type-directed design of synthetic enhancers. *Nature*, 626:212–220, 2024. doi: 10.1038/s41586-023-06936-2.
- [21] S. J. Gosai, R. I. Castro, N. Fuentes, et al. Machine-guided design of cell-type-targeting cis-regulatory elements. *Nature*, 634:1211–1220, 2024. doi: 10.1038/s41586-024-08070-z.
- [22] Eeshit D. Vaishnav, Carl G. de Boer, Jason Molinet, et al. The evolution, evolvability and engineering of gene regulatory DNA. *Nature*, 603:455–463, 2022. doi: 10.1038/s41586-022-04506-6.
- [23] Bernardo P. de Almeida et al. Targeted design of synthetic enhancers for selected tissues in the drosophila embryo. *Nature*, 626:207–211, 2024. doi: 10.1038/s41586-023-06905-9.
- [24] Sean Whalen, Jacob Schreiber, William S. Noble, and Katherine S. Pollard. Navigating the pitfalls of applying machine learning in genomics. *Nature Reviews Genetics*, 23(3):169–181, 2022. doi: 10.1038/s41576-021-00434-9.
- [25] Carl G. de Boer and Jussi Taipale. Hold out the genome: a roadmap to solving the cis-regulatory code. *Nature*, 625:41–50, 2024. doi: 10.1038/s41586-023-06661-w.
- [26] Yaniv Ovadia, Emily Fertig, Jie Ren, et al. Can you trust your model’s uncertainty? evaluating predictive uncertainty under dataset shift. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [27] Abdul Muntakim Rafi, Daria Nogina, Dmitry Penzar, et al. A community effort to optimize sequence-based deep learning models of gene regulation. *Nature Biotechnology*, 43:1373–1383, 2025. doi: 10.1038/s41587-024-02414-w.
- [28] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016. doi: 10.1109/CVPR.2016.90.
- [29] Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [30] Yarin Gal and Zoubin Ghahramani. Dropout as a Bayesian approximation: Representing model uncertainty in deep learning. In *International Conference on Machine Learning (ICML)*, pages 1050–1059, 2016.
- [31] Charles Blundell, Julien Cornebise, Koray Kavukcuoglu, and Daan Wierstra. Weight uncertainty in neural networks. In *International Conference on Machine Learning (ICML)*, pages 1613–1622, 2015.

- [32] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [33] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014.
- [34] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.
- [35] Adam Paszke, Sam Gross, Francisco Massa, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [36] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. doi: 10.1038/s41586-020-2649-2.
- [37] Wes McKinney. Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61, 2010.
- [38] John D. Hunter. Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007. doi: 10.1109/MCSE.2007.55.