

补充信息

跨模型不确定性感知的顺式调控元件最小编辑：细胞类型选择性设计

夏昂然

陕西师范大学化学化工学院

陕西省西安市长安区西长安街 620 号 710119

通信邮箱: haangyeon@snnu.edu.cn

目录

1	补充方法与审计说明	2
1.1	研究阶段与角色分离	2
1.2	完整性检查	2
2	补充结果	2
2.1	数据划分与预测器性能	2
2.2	G4 硬性审计分层	4
2.3	G8 冻结后终点与异质性	4
2.4	G9 真实搜索消融	6
2.5	候选文库	6
2.6	代表性 Tier A 候选	7
3	可重复性总结	10

1 补充方法与审计说明

1.1 研究阶段与角色分离

本研究按序贯阶段执行。G0–G3 建立了数据审计、已发表模型重现、试点 CNN 评审器以及初始编辑工作流。G4 冻结了 90 亲本、三方法的硬性审计基准（6 个名义亲本因与 G4 探索性试点重叠而被排除）。G6 分配了计算候选层级。G7 训练了全数据残基-扩张评审器和多核冻结后评估器。G8 选择了 600 个新亲本并比较了四种搜索方法。G9 在 180 个亲本上重运行了七种完整搜索配置。G10 应用了冻结后终点并组装了汇总分析。活性标签从未用于选择亲本或候选序列。

术语评审器和冻结后评估器表示不同的角色。评审器在 G8/G9 搜索期间可供 SafeEdit 使用。冻结后评估器仅在候选文件冻结后才加载。两者均在相同的公开 MPRA 源表上训练；因此”冻结后”描述的是与搜索的程序分离，而非外部生物学独立性。

1.2 完整性检查

最终 G9 表包含 15,120 行、180 个唯一条本、七种配置、三个靶细胞和四个预算。不存在重复的亲本–靶标–预算–配置键，无非有限数值，可行设计中无精确编辑预算违规。G8 折叠表包含 28,800 行方法级记录和 600 个亲本。随机指标是三次独立重复的均值；折叠表不得用于选择特定 DNA 序列。

所有投稿载荷均在手稿生成后重新检查。发布清单包含每个载荷文件的 SHA-256 校验和，且清单本身不参与自哈希计算。

2 补充结果

2.1 数据划分与预测器性能

表 1: 表 S1。用于 G7 模型训练的质量过滤后全数据划分。

划分	记录数	染色体	用途
训练集	627,661	排除验证/测试的符合条件染色体	参数拟合
验证集	58,811	19、21、X	检查点选择和方差缩放
测试集	62,582	7、13	最终预测诊断
总计	749,054	–	质量过滤和精确去重后

表 2: 表 S2。62,582 条记录测试拆分上的集成性能，从保存的候选独立预测表重新计算。

模型	细胞	Pearson r	Spearman ρ	MAE	不确定性–误差 ρ
评审器	K562	0.845	0.781	0.396	0.448
评审器	HepG2	0.855	0.809	0.354	0.404
评审器	SK-N-SH	0.847	0.810	0.390	0.399
冻结后评估器	K562	0.785	0.719	0.463	0.467
冻结后评估器	HepG2	0.795	0.743	0.417	0.416
冻结后评估器	SK-N-SH	0.799	0.760	0.444	0.400

表 3: 表 S3。测试拆分上的验证缩放区间覆盖率。

模型	细胞	80% 区间	90% 区间	95% 区间
评审器	K562	0.815	0.897	0.935
评审器	HepG2	0.794	0.885	0.930
评审器	SK-N-SH	0.814	0.900	0.940
冻结后评估器	K562	0.821	0.900	0.935
冻结后评估器	HepG2	0.789	0.879	0.923
冻结后评估器	SK-N-SH	0.816	0.899	0.935




图 1: 图 S1。不确定性拒绝与区间校准。A–B，随着预测不确定性最大的记录从留出测试集中移除，评审器和冻结后集成的平均绝对误差变化。C–D，按细胞类型划分的 80%、90% 和 95% 名义水平下的观测测试覆盖率。曲线和柱状图为描述性测试诊断；方差尺度仅从验证集固定。

2.2 G4 硬性审计分层

表 4: 表 S4。按靶细胞和编辑预算划分的 G4 审计通过率。每行包含 90 个非重叠亲本/方法，排除了 6 个与 G4 探索性试点重叠的亲本。

靶标	预算	随机 (%)	贪婪 (%)	SafeEdit(%)	SafeEdit-贪婪 (pp)
K562	1	14.4	58.9	60.0	1.1
K562	5	8.9	56.7	77.8	21.1
K562	10	17.8	43.3	82.2	38.9
K562	20	24.4	50.0	81.1	31.1
HepG2	1	8.9	34.4	35.6	1.1
HepG2	5	5.6	35.6	45.6	10.0
HepG2	10	2.2	33.3	56.7	23.3
HepG2	20	8.9	27.8	60.0	32.2
SK-N-SH	1	24.4	36.7	38.9	2.2
SK-N-SH	5	17.8	35.6	57.8	22.2
SK-N-SH	10	15.6	22.2	64.4	42.2
SK-N-SH	20	8.9	31.1	66.7	35.6

2.3 G8 冻结后终点与异质性

表 5: 表 S5。合并的 G8 方法汇总。每种方法在三次随机重复取平均后有 7,200 条亲本-靶标-预算记录。

方法	裕度增益	靶标增益	正裕度比例 (%)	不确定性
随机匹配	0.001	0.012	48.6	0.185
贪婪 Malinois	0.822	1.803	97.1	0.329
主束	0.881	1.866	94.8	0.335
SafeEdit 共识	0.877	1.661	95.4	0.314

表 6: 表 S6。合并的配对 G8 对比。差值为 SafeEdit 减去对照；置信区间使用 100,000 次亲本簇自助重复。

对照	指标	平均差值	95% CI
贪婪	冻结后裕度增益	0.0555	0.0398 至 0.0705
贪婪	冻结后靶标增益	-0.1412	-0.1774 至 -0.1057
贪婪	冻结后不确定性	-0.0153	-0.0214 至 -0.0091
主束	冻结后裕度增益	-0.0036	-0.0114 至 0.0042
主束	冻结后靶标增益	-0.2048	-0.2294 至 -0.1808
主束	冻结后不确定性	-0.0209	-0.0251 至 -0.0166
随机匹配	冻结后裕度增益	0.8763	0.8562 至 0.8960
随机匹配	冻结后靶标增益	1.6494	1.6034 至 1.6950
随机匹配	冻结后不确定性	0.1285	0.1222 至 0.1348




图 2: 图 S2. G8 冻结后终点中的靶标-预算异质性。 A–C, K562、HepG2 和 SK-N-SH 中随机、贪婪、主束和 SafeEdit 搜索在不同编辑预算下的平均冻结后特异性裕度增益。每个点汇总 600 个亲本。数值为描述性, 未做多重性校正。

2.4 G9 真实搜索消融

表 7: 表 S7。七种独立重运行搜索配置的 G9 冻结后结果。每种配置包含 2,160 行，来自 180 个亲本、三个靶标和四个预算。

配置	裕度增益	靶标增益	正例比例 (%)	不确定性	不可行
主束	0.890	1.897	94.7	0.334	48
SafeEdit 完整	0.890	1.705	95.3	0.312	48
无评审得分	0.890	1.897	94.7	0.334	48
无不确定性惩罚	0.891	1.719	95.2	0.313	48
无链惩罚	0.887	1.701	95.4	0.310	48
无天然性重排序	0.979	2.017	95.3	0.343	48
无序列预过滤器	0.910	1.763	98.1	0.318	0

表 8: 表 S8。选定的 G9 配对对比。差值为完整 SafeEdit 减去消融配置；区间使用 100,000 次亲本簇自助重复。

对照	指标	平均差值	95% CI
主束	冻结后裕度增益	0.0002	−0.0145 至 0.0151
主束	冻结后靶标增益	−0.1920	−0.2440 至 −0.1432
主束	冻结后不确定性	−0.0212	−0.0283 至 −0.0140
无天然性	冻结后裕度增益	−0.0888	−0.1022 至 −0.0754
无天然性	冻结后靶标增益	−0.3117	−0.3600 至 −0.2658
无天然性	冻结后不确定性	−0.0305	−0.0394 至 −0.0218
无预过滤器	冻结后裕度增益	−0.0198	−0.0387 至 −0.0043
无预过滤器	冻结后靶标增益	−0.0581	−0.1021 至 −0.0227
无预过滤器	冻结后不确定性	−0.0060	−0.0102 至 −0.0024

2.5 候选文库




图 3: 图 S3. 计算候选层级。冻结的 3,240 条序列 G4 文库的主模型和评审特异性裕度增益。所有 Tier A 和 Tier B 候选均被绘制；Tier C 为可读性进行了降采样。带轮廓的点位于计算的帕累托前沿上。层级标签表示实验筛选的计算优先级。

表 9: 表 S9. 冻结的 G4 候选层级。

层级	候选数	比例 (%)	预期用途
A	74	2.3	最高优先级实验组
B	1,141	35.2	备选计算候选
C	2,025	62.5	方法与失效模式分析

2.6 代表性 Tier A 候选

∞

表 10: 表 S10。三个代表性 Tier A 报告基因筛选候选，每种细胞类型一个，选自锁定的非重叠 90 亲本九准则设计基准。代表性示例按预设规则选择：要求 Tier A 状态、每种靶细胞一个示例、正的跨模型裕度增益、降低的不确定性、无合成风险标记。裕度显示主 Malinois 预测器和留出评审集成的结果；三者均达到帕累托前沿状态且无合成风险标记。编辑位置使用 200-nt 序列窗口内的 0 索引坐标。裕度和不确定性值以 log 倍变化单位表示。GC 以分数表示。所有编辑均为 5 个核苷酸预算内的替换。编辑位置的基序水平观测作为可检验的序列语法假说报告，供后续研究。

属性	K562 (chr7:127284707)		HepG2 (chr7:105701659)		SK-N-SH (chr13:23368564)	
	亲本	编辑后	亲本	编辑后	亲本	编辑后
编辑预算	5		5		5	
编辑位置	89, 118, 130, 132, 180		89, 94, 99, 112, 199		1, 148, 149, 171, 174	
编辑详情	89T>A; 118C>G; 130A>T; 132C>A; 180C>A		89G>T; 94C>A; 99G>C; 112G>C; 199C>G		1C>G; 148T>C; 149C>T; 171A>G; 174C>A	
主裕度	-0.372	+4.204	-0.620	+5.100	+0.020	+2.874
评审裕度	-0.138	+0.002	-0.068	+0.003	-0.197	-0.097
主裕度增益		+4.577		+5.719		+2.854
评审裕度增益		+0.140		+0.070		+0.100
主靶标增益		+4.558		+6.093		+3.427
评审不确定性	1.253	1.099	1.243	1.143	0.552	0.445
不确定性变化		-0.154		-0.100		-0.107
GC 含量	0.575	0.565	0.570	0.560	0.365	0.365
天然性变化		+0.056		+0.006		+0.028
最大同源多聚体	4	4	5	5	5	5
合成风险		无		无		无
帕累托前沿		是		是		是
亲本序列	TGAGGGCAGAGCTCAGCCGCAACCCGGCCCTGCTGCTTAGAGGCTCGGGGCCTTGGCAAATGACAGCCTCCCTGAGCCTGTTTCTCCATCCGTA AAAACAGGCCTCCCAGCCCTGTGTGCGAGCAACTGAAACGAGGGTTAAATGAGGAAACCATGCGACAGATGTCAGCATAATCCCTGCGCAGAG					
编辑后序列 (K562)	TGAGGGCAGAGCTCAGCCGCAACCCGGCCCTGCTGCTTAGAGGCTCGGGGCCTTGGCAAATGACAGCCTCCCTGAGCCTGTTTCTCCAACCGTA AAAACAGGCCTCCCAGCCCTGTGTGGGAGCAACTGATAAGAGGGTTAAATGAGGAAACCATGCGACAGATGTCAGCATAATCCCTGCGCAGAG					
亲本序列 (HepG2)	GGGGGTGAGGGATCCCTGCAATACATAACACGTGCTAAGCAGTGGGGTTTGGGTGCTACTTCCCAACTGGCCGCTCTTAGGAACTGGTGAAACCTTAAGTCAGGTGTGACTGAGCGAGCCCTGGGTGTCATGGCTATTCTCCTTGCTGCTGCTCTCTCTAAGTCTGGTTTGAGGCTCCTGCGCCCTCCCT					

SafeEdit-CRE 补充信息

调查基因组学与设计

[illegible]

3 可重复性总结

亲本选择是确定性的且标签盲的，在构建基准前移除了所有历史标识符、序列哈希和审计标记的冲突。冻结后评估器仅在候选文件及其 SHA-256 清单写入后才加载。计算量匹配的束使用与 SafeEdit 相同的束宽、扩展深度和预筛选大小；随机比较取三次固定重复的平均。最终置信区间使用 100,000 次亲本簇自助重复。所有七种消融配置均重运行了完整搜索，每张报告的图和表均可从分析脚本附带的候选级数据重新生成。